



NOTE DE RÉPLICATION EXPLORATOIRE

Reproductibilité et invariance du G-score à travers les baromètres NeoMundi

*Étude statistique de la stabilité du score se-
lon les modèles, les prompts et les campagnes*

Fatima Ezzahrae GOUARAB

Data Scientist · Contributrice scientifique, Observatoire NeoMundi Recherche
neomundi.org/contributeurs

Résumé

Le score G est utilisé dans le dispositif NeoMundi pour caractériser les sorties produites par différents grands modèles de langage (LLM). À la suite d'un premier travail consacré à sa reproductibilité, cette étude approfondit l'analyse à partir d'un ensemble de 33 600 observations issues de douze modèles, sept campagnes et quatre prompts répétés.

L'analyse met en évidence un comportement stable du score dans les conditions de référence, mais aussi une variation marquée lors d'une campagne particulière. Le niveau observé en B5 s'écarte nettement de celui des campagnes précédentes, avant de retrouver des valeurs proches de la référence lors des campagnes suivantes. L'ampleur de cette variation n'est par ailleurs pas identique entre les modèles.

Les différentes analyses statistiques permettent ainsi de distinguer ce qui relève d'une stabilité générale du score de ce qui dépend des conditions dans lesquelles il est mesuré. Les résultats ne conduisent pas à retenir une invariance stricte, mais mettent plutôt en évidence une stabilité conditionnelle, avec une reproductibilité variable selon les configurations et une sensibilité lors de changements de régime.

Cette analyse fournit ainsi une caractérisation quantitative du comportement du score G dans le contexte de l'évaluation des LLM. Elle permet également d'identifier les limites actuelles de l'interprétation du score et les conditions qui devront être examinées dans une étude élargie.

Mots-clés : G-score ; LLM ; évaluation des LLM ; reproductibilité ; invariance ; variabilité inter-modèles ; robustesse statistique.

Liste des abréviations

B Baromètre

G-score Score G

LLM Large Language Model (grand modèle de langage)

ICC Intraclass Correlation Coefficient (coefficient de corrélation intraclasse)

IC Intervalle de confiance

IQR Interquartile Range (écart interquartile)

CV Coefficient de variation

p Valeur de p associée au test statistique

ρ_s Coefficient de corrélation de Spearman

χ^2 Statistique du test du rapport de vraisemblance

ddl Degrés de liberté

Table des matières

Liste des abréviations	2
1. Contexte, problématique et objectifs	7
1.1. Contexte	7
1.2. Problématique.	7
1.3. Objectifs	8
2. Données et protocole expérimental	9
2.1. Description du corpus.	9
2.2. Variables analysées	9
2.3. Organisation des répétitions.	9
2.4. Définition des périodes	10
2.5. Contrôle qualité et préparation des données	10
2.6. Méthodes statistiques et justification.	11
2.6.1. <i>Synthèse du choix des méthodes</i>	11
2.6.2. <i>Statistiques descriptives</i>	13
2.6.3. <i>Coefficient de variation</i>	13
2.6.4. <i>Coefficient de corrélation intraclasse</i>	13
2.6.5. <i>Autocorrélation des répétitions</i>	14
2.6.6. <i>Test de Mann–Whitney</i>	15
2.6.7. <i>Delta de Cliff</i>	15
2.6.8. <i>Modèle linéaire mixte</i>	17
2.6.9. <i>Corrélation de Spearman</i>	17
2.6.10. <i>Détection des valeurs atypiques</i>	18
2.6.11. <i>Analyse de sensibilité et robustesse</i>	18
2.6.12. <i>Principe général d’interprétation</i>	18
3. Résultats	20
3.1. Distribution et reproductibilité du G-score	20
3.1.1. <i>Niveau et dispersion du G-score</i>	20
3.1.2. <i>Stabilité du score au cours des répétitions</i>	21
3.1.3. <i>Évaluation quantitative de la reproductibilité</i>	22
3.2. Hétérogénéité du G-score entre les modèles	23
3.2.1. <i>Comparaison globale des modèles</i>	24
3.2.2. <i>Comparaisons post-hoc entre modèles</i>	24
3.3. Rupture du G-score au baromètre B5	25
3.3.1. <i>Mise en évidence de la rupture</i>	25
3.3.2. <i>Amplitude de la différence entre la référence et B5</i>	25
3.3.3. <i>Hétérogénéité de la rupture selon les modèles</i>	26

3.3.4. Variables d'exécution associées au G-score	27
3.4. Évolution du G-score après B5.	28
3.4.1. Comparaison globale : référence, B7 et B8	28
3.4.2. Hétérogénéité de l'évolution selon les modèles	28
3.4.3. Amplitude du retour par modèle	29
3.4.4. Trajectoire complète après la rupture.	30
3.5. Robustesse des résultats aux valeurs atypiques	31
3.5.1. Identification des valeurs atypiques.	31
3.5.2. Analyse de sensibilité.	31
3.5.3. Erreurs d'exécution selon les baromètres.	32
4. Discussion.	33
4.1. Synthèse des résultats.	33
4.2. Évaluation de l'hypothèse d'invariance	34
4.3. Limites de l'étude	34
4.4. Perspectives pour une étude plus large	35
5. Annexes	36
5.1. Annexe – Niveau moyen du G-score selon le modèle et le baromètre	36
5.2. Annexe — Reproductibilité : ICC(1,1) par modèle et par baromètre	37
5.3. Annexe – Comparaisons post-hoc entre modèles	37
5.4. Annexe – Trajectoires du G-score par modèle et par baromètre	39
5.5. Annexe – Valeurs atypiques par baromètre	39
Références	40

Liste des figures

1	Distribution du G-score selon le baromètre.	20
2	Évolution du G-score au fil des répétitions sur les baromètres de référence B1–B4. Les bandes indiquent les IC à 95 %.	21
3	Dispersion relative du G-score selon le modèle sur les baromètres de référence B1–B4, mesurée par le coefficient de variation.	22
4	Évolution du G-score moyen entre les baromètres B1 et B5.	25
5	Distribution du G-score : période de référence B1–B4 et baromètre B5, représentée sous forme de densité normalisée.	26
6	Écart estimé du G-score en B7 et B8 par rapport à la période de référence, selon le modèle.	29
7	Trajectoire du G-score moyen entre la période de référence, B5, B7 et B8.	30
8	Heatmap-Moyenne du G score selon le modèle et le baromètre	36
9	Trajectoire du G-score entre la période de référence, B5, B7 et B8, avec représentation des trajectoires individuelles des modèles.	39

Liste des tableaux

1	Correspondance entre les questions scientifiques et les méthodes statistiques.	12
2	Statistiques descriptives du G-score par modèle sur les baromètres de référence B1–B4.	24
3	Corrélations de Spearman entre le G-score et les variables d'exécution, selon la période.	27
4	Sensibilité du G-score à l'exclusion des observations identifiées comme atypiques.	31
5	Nombre et taux d'erreurs d'exécution selon le baromètre.	32
6	ICC(1,1) par modèle et par baromètre sur la période de référence B1–B4. Les valeurs indiquées par – correspondent aux combinaisons pour lesquelles l'ICC n'est pas estimable.	37
7	Paires de modèles statistiquement significatives (test de Dunn, correction de Holm), avec delta de Cliff associé. Période de référence B1–B4. Les 22 paires sont toutes d'amplitude négligeable.	37
8	Répartition des observations identifiées comme atypiques selon le baromètre.	39

1. Contexte, problématique et objectifs

1.1. Contexte

Une première étude, intitulée *Stabilité et reproductibilité du signal runtime NeoMundi ControlTower*, a porté sur la stabilité et la reproductibilité des signaux produits par le dispositif NeoMundi. Cette première phase, fondée sur 680 générations issues de trois fournisseurs de modèles et de plusieurs jeux de données, a permis d'établir les premières observations sur le comportement du signal et d'identifier notamment un changement de régime dont l'évolution devait être suivie dans le temps.

La présente étude s'inscrit directement dans cette continuité. Elle vise à examiner plus largement la reproductibilité du G-score et à tester l'hypothèse selon laquelle certaines de ses propriétés restent stables lorsque les conditions expérimentales varient. L'analyse est ainsi étendue à un volume de données nettement plus important et à un ensemble plus large de modèles, de prompts et de campagnes de mesure.

L'analyse porte sur 33 600 observations issues de douze modèles, sept campagnes de mesure et quatre prompts, chacun étant répété cent fois pour chaque combinaison modèle–campagne–prompt. Cette structure permet d'étudier conjointement la variabilité entre répétitions, les différences entre modèles et prompts, ainsi que les variations du score entre les différentes campagnes.

L'enjeu est ainsi de distinguer ce qui relève d'une reproductibilité observée dans des conditions comparables de ce qui pourrait constituer une propriété plus générale du score. Une bonne reproductibilité dans une configuration donnée ne suffit en effet pas, à elle seule, à établir une invariance générale du G-score.

1.2. Problématique

La question centrale de l'étude est la suivante :

Dans quelle mesure le score G présente-t-il un comportement stable et reproductible lorsque les répétitions, les modèles, les prompts et les campagnes de mesure varient ?

Cette question conduit à distinguer deux niveaux qui ne doivent pas être confondus : la reproductibilité d'une mesure dans des conditions données, et l'invariance du score lorsque ces conditions changent. Une bonne reproductibilité ne suffit donc pas, à elle seule, à établir que le score possède un comportement invariant.

L'analyse porte ainsi sur la stabilité du score au sein des répétitions, sur sa variabilité entre modèles et prompts, puis sur son évolution entre les campagnes. Une attention particulière est accordée au baromètre B5, qui constitue une rupture apparente dans le niveau du

G-score. Il s'agit notamment de déterminer si cette variation concerne l'ensemble des modèles, si son amplitude diffère selon eux, et si le score retrouve ensuite des niveaux proches de ceux observés avant cette rupture.

L'hypothèse d'invariance du score G n'est donc pas posée comme un résultat à démontrer, mais comme une hypothèse à évaluer à partir des données.

1.3. Objectifs

L'objectif principal est de caractériser quantitativement la reproductibilité et la stabilité du score G sur un volume étendu d'exécutions, et d'identifier les conditions dans lesquelles ces propriétés sont préservées ou remises en question.

L'analyse vise plus précisément à :

- caractériser la distribution et la dispersion du G-score ;
- évaluer la reproductibilité des répétitions d'un même prompt ;
- mesurer la variabilité entre modèles et entre prompts ;
- comparer les niveaux du score entre les différentes campagnes ;
- identifier et caractériser d'éventuelles ruptures de régime, notamment autour de B5 ;
- déterminer si l'amplitude des variations observées dépend du modèle ou des conditions de mesure ;
- examiner les relations entre le G-score et les variables d'exécution disponibles, notamment la latence, le nombre de tokens et les erreurs techniques ;
- évaluer la robustesse des résultats aux observations atypiques et aux choix de traitement des données ;
- déterminer dans quelle mesure les résultats soutiennent ou remettent en question l'hypothèse d'invariance du score G.

Pour répondre à ces questions, l'étude combine statistiques descriptives, mesures de reproductibilité, tests de comparaison, analyses de corrélation, modèles à effets mixtes et analyses de sensibilité. Cette approche permet de considérer non seulement l'existence de différences statistiques, mais également leur ampleur, leur incertitude et leur robustesse.

2. Données et protocole expérimental

2.1. Description du corpus

L'étude s'appuie sur sept campagnes de mesure, menées entre juin et août 2026 et désignées baromètres 1 à 5, puis 7 et 8. Le baromètre 6 n'a jamais été transmis, laissant un intervalle du 20 au 29 juillet sans observation disponible, une absence qui n'affecte pas la validité des analyses conduites, mais qu'il convient de signaler par souci de transparence sur la continuité temporelle du dispositif.

Chacune de ces campagnes interroge douze fournisseurs d'intelligence artificielle distincts, couvrant un éventail large de l'offre commerciale actuelle : Anthropic, Cohere, DeepSeek, Google, Mistral, ainsi que deux modèles hébergés par Infomaniak, OpenAI, Perplexity, Qwen, Together et xAI. Pour chaque modèle, quatre prompts identiques sont soumis, eux-mêmes répétés cent fois. Cette architecture, une fois entièrement consolidée, produit un dataset canonique de 33 600 observations, issu de 84 fichiers retenus sur les 112 initialement reçus.

2.2. Variables analysées

Le score G constitue la variable d'intérêt principale de cette étude. Il est accompagné de plusieurs variables contextuelles qui permettent d'en éclairer le comportement : l'identité du modèle interrogé, le prompt soumis, la campagne de mesure concernée, le numéro de répétition, ainsi que des variables d'exécution telles que la latence de réponse, le nombre de tokens générés, et la présence éventuelle d'une erreur technique lors de l'appel. Une décision de gouvernance (autorisée ou signalée) accompagne chaque observation, offrant un second angle d'analyse indépendant du score lui-même.

2.3. Organisation des répétitions

Chaque prompt est soumis cent fois à un même modèle, au sein d'une même campagne. Cette répétition volontaire vise précisément à mesurer la reproductibilité du score, mais elle implique une conséquence méthodologique qu'il serait imprudent d'ignorer : les cent observations issues d'un même prompt ne constituent pas cent unités statistiquement indépendantes. Elles proviennent d'une seule et même condition expérimentale, répétée dans le temps, et partagent à ce titre une source de variabilité commune. De la même façon, les observations d'un même modèle à travers les différentes campagnes ne sont pas totalement indépendantes les unes des autres. Cette structure hiérarchique, examinée plus en détail dans la section méthodologique, a orienté le choix de plusieurs outils statistiques employés par la suite, en particulier le recours à un modèle à effets mixtes pour les questions où cette dépendance ne pouvait raisonnablement être ignorée.

2.4. Définition des périodes

Trois périodes distinctes structurent l'ensemble des analyses temporelles conduites dans cette étude. Les baromètres 1 à 4 constituent la période de référence, aucun incident n'y ayant été détecté. Le baromètre 5 est traité à part, sous l'appellation de période de rupture, en raison des anomalies qui y ont été observées et qui font l'objet d'un examen approfondi en section 7. Les baromètres 7 et 8, enfin, constituent la période de suivi, dont l'analyse permet de déterminer si les particularités du baromètre 5 se sont prolongées ou résorbées. Il convient de souligner que cette dernière période n'a pas été présumée stable a priori : sa qualification comme période de suivi cohérente avec la référence résulte des analyses présentées en section 8, non d'une hypothèse posée en amont.

2.5. Contrôle qualité et préparation des données

Pour chaque combinaison modèle-campagne, le fichier retenu est celui comportant le moins d'erreurs techniques, le nombre de lignes complètes servant de critère de départage en cas d'égalité. Douze combinaisons, toutes rattachées au baromètre 5, ont nécessité plusieurs tentatives d'exécution avant qu'un résultat exploitable ne soit obtenu, de trois à sept essais selon le modèle concerné.

Un test de sensibilité a été conduit pour s'assurer que ce choix méthodologique n'orientait pas artificiellement les conclusions. En recalculant la moyenne du baromètre 5 à partir de la pire tentative disponible pour chaque modèle plutôt que de la meilleure, l'écart introduit ne dépasse pas 0,011 point, à comparer aux 0,07 point séparant cette période de la référence : la sélection des fichiers ne saurait donc expliquer, même partiellement, l'ampleur de la rupture observée.

Une fois les données fusionnées, plusieurs vérifications ont porté sur l'ensemble du jeu de données : absence de doublons, structure complète des répétitions, cent occurrences numérotées de un à cent, sans trou ni chevauchement, pour chacune des 336 combinaisons modèle-campagne-prompt, absence de valeur impossible pour le score G, et cohérence des 84 combinaisons attendues. Cent quatre-vingt-dix-neuf lignes sur 33 600, soit 0,592 %, demeurent en erreur technique, majoritairement concentrées sur un seul modèle au baromètre 8 ; le score G y est systématiquement absent, sans conséquence sur les moyennes calculées ailleurs dans l'étude.

2.6. Méthodes statistiques et justification

L'analyse statistique a été conçue afin de répondre aux différentes dimensions de la problématique : caractériser la distribution du score G, mesurer sa variabilité, évaluer sa reproductibilité entre répétitions, comparer les comportements entre modèles et campagnes, puis tester la robustesse des différences observées.

Le choix des méthodes repose sur la structure du jeu de données et sur les propriétés empiriques du score G. Les observations sont répétées selon les prompts et les indices de répétition, tandis que les distributions peuvent présenter des formes non gaussiennes. Une combinaison de statistiques descriptives, de méthodes non paramétriques, de mesures de taille d'effet, d'analyses de corrélation et de modèles à effets mixtes est donc utilisée.

L'objectif n'est pas uniquement de déterminer si une différence est statistiquement significative. Il s'agit également d'en mesurer l'ampleur, d'évaluer son incertitude, et de déterminer si elle reste robuste lorsque la structure des données ou les observations atypiques sont prises en compte.

2.6.1. Synthèse du choix des méthodes

Le tableau 1 résume la correspondance entre les questions scientifiques, les hypothèses statistiques et les méthodes retenues.

Question	H_0	H_1	Méthode
Quelle est la dispersion du score G ?	—	—	Statistiques descriptives, CV
Les répétitions d'un même prompt sont-elles reproductibles ?	Absence de concordance particulière	Concordance entre répétitions	ICC(1,1)
Les répétitions successives présentent-elles une dépendance ?	$\rho_1 = 0$	$\rho_1 \neq 0$	Autocorrélation
Les modèles présentent-ils des distributions différentes ?	Même distribution de position	Au moins un modèle diffère	Kruskal–Wallis
Quelles paires de modèles diffèrent ?	Pas de différence entre les deux groupes	Différence entre les deux groupes	Dunn + Holm
B5 diffère-t-elle de B1–B4 ?	Distributions comparables	Distributions différentes	Mann–Whitney
Quelle est l'ampleur de cette différence ?	$\delta = 0$	$\delta \neq 0$	Delta de Cliff
L'effet de la période dépend-il du modèle ?	$\beta_{\text{interaction}} = 0$	$\beta_{\text{interaction}} \neq 0$	Modèle mixte
L'interaction améliore-t-elle le modèle ?	M_0 suffit	M_1 améliore l'ajustement	Rapport de vraisemblance
Le score G est-il associé aux variables d'exécution ?	$\rho_s = 0$	$\rho_s \neq 0$	Spearman
Les résultats dépendent-ils des valeurs atypiques ?	Résultats similaires	Modification substantielle	IQR + sensibilité

Table 1. Correspondance entre les questions scientifiques et les méthodes statistiques.

Pour l'ensemble des tests d'hypothèse, le seuil de significativité est fixé à $\alpha = 0,05$. Une significativité statistique n'est cependant pas considérée comme suffisante, à elle seule, pour conclure à une différence importante : les résultats sont systématiquement interprétés conjointement avec l'amplitude des effets et, lorsque cela est disponible, avec leurs intervalles de confiance.

2.6.2. Statistiques descriptives

La première étape consiste à décrire la distribution du score G à l'aide de la moyenne, de la médiane, de l'écart-type, des quartiles et des valeurs extrêmes, calculés selon les dimensions pertinentes de l'étude (modèle, prompt, période). Pour un ensemble de n observations, la moyenne est définie par

$$\bar{G} = \frac{1}{n} \sum_{i=1}^n G_i, \quad (1)$$

et l'écart-type empirique correspondant par

$$s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (G_i - \bar{G})^2}. \quad (2)$$

Les intervalles de confiance à 95 % associés à chaque moyenne sont obtenus par rééchantillonnage bootstrap non paramétrique : à partir d'un échantillon de taille n , B répliques sont générées par tirage avec remise, chacune produisant une moyenne $\bar{G}_b^*$ ($b = 1, \dots, B$), et l'intervalle de confiance correspond aux quantiles empiriques à 2,5 % et 97,5 % de la distribution obtenue. Cette approche est préférée à une formule reposant sur la loi normale, hypothèse difficilement défendable compte tenu du caractère discret du score G .

2.6.3. Coefficient de variation

Le coefficient de variation est utilisé pour comparer la dispersion relative du score G entre modèles, à un niveau moyen éventuellement différent :

$$CV = \frac{s}{\bar{G}}. \quad (3)$$

Cette normalisation évite d'attribuer à une instabilité réelle ce qui ne serait, en partie, qu'un effet d'échelle entre modèles n'affichant pas le même niveau moyen. Le CV est utilisé ici comme indicateur descriptif de variabilité ; il ne constitue pas à lui seul un test d'invariance.

2.6.4. Coefficient de corrélation intraclass

La reproductibilité des mesures répétées est évaluée à l'aide du coefficient de corrélation intraclass,

$$ICC = \frac{\sigma_{\text{entre}}^2}{\sigma_{\text{entre}}^2 + \sigma_{\text{intra}}^2}, \quad (4)$$

où, pour un modèle et un baromètre donnés, σ_{entre}^2 désigne la variance entre les moyennes des $p = 4$ prompts,

$$\sigma_{\text{entre}}^2 = \frac{1}{p-1} \sum_{j=1}^p (\bar{G}_j - \bar{\bar{G}})^2, \quad (5)$$

et σ_{intra}^2 la variance des répétitions au sein d'un même prompt, moyennée sur l'ensemble des prompts,

$$\sigma_{\text{intra}}^2 = \frac{1}{p} \sum_{j=1}^p \left[\frac{1}{n-1} \sum_{k=1}^n (G_{jk} - \bar{G}_j)^2 \right]. \quad (6)$$

L'ICC est calculé séparément pour chaque combinaison modèle-baromètre sur les campagnes B1 à B4 ; la version retenue, ICC(1,1), correspond à l'évaluation de la fiabilité d'une mesure individuelle. Une valeur proche de un indique une forte concordance relative des mesures, tandis qu'une valeur proche de zéro traduit une reproductibilité plus limitée. Cet indicateur est interprété avec prudence : sa valeur dépend étroitement de σ_{entre}^2 , or le nombre de prompts disponibles reste limité à quatre, et plusieurs combinaisons modèle-baromètre n'ont pas permis son calcul faute d'un nombre suffisant de prompts valides après filtrage. L'ICC est ainsi complémentaire au CV : le CV caractérise la dispersion relative, tandis que l'ICC est spécifiquement orienté vers la concordance des mesures répétées.

2.6.5. Autocorrélation des répétitions

Une analyse d'autocorrélation est réalisée afin d'étudier une éventuelle dépendance entre deux répétitions successives d'une même condition expérimentale, après classement des observations selon l'indice de répétition, pour chaque combinaison modèle-prompt-baromètre. L'autocorrélation au premier retard s'exprime par

$$\rho_1 = \frac{\sum_{t=2}^n (G_t - \bar{G})(G_{t-1} - \bar{G})}{\sum_{t=1}^n (G_t - \bar{G})^2}. \quad (7)$$

L'hypothèse nulle correspond à l'absence d'autocorrélation :

$$H_0 : \rho_1 = 0 \quad \text{contre} \quad H_1 : \rho_1 \neq 0.$$

Une valeur proche de zéro indique une faible dépendance linéaire entre deux répétitions successives, tandis qu'une valeur plus importante, positive ou négative, indique une dépendance potentielle. Cette analyse est considérée comme exploratoire ; elle permet de vérifier la structure des répétitions avant la construction du modèle mixte.

2.6.6. Test de Mann–Whitney

Pour les comparaisons entre deux groupes, notamment entre la période de référence et B5, le test de Mann–Whitney est utilisé plutôt que le test t , dont l’hypothèse de normalité ne peut raisonnablement être retenue compte tenu du caractère discret du score G . Les $n_1 + n_2$ observations des deux échantillons sont classées ensemble par ordre croissant ; R_1 désigne la somme des rangs attribués aux n_1 observations du premier échantillon. La statistique de test s’écrit

$$U = n_1 n_2 + \frac{n_1(n_1 + 1)}{2} - R_1, \quad (8)$$

et suit, sous l’hypothèse nulle d’égalité des distributions, une loi dont la moyenne et la variance sont connues analytiquement pour des échantillons de grande taille. Ce test ne mesure pas l’amplitude de la différence détectée ; celle-ci est évaluée séparément avec le delta de Cliff.

2.6.7. Delta de Cliff

Un test de significativité ne renseigne pas, à lui seul, sur l’ampleur d’une différence. Avec un volume d’observations important, des écarts de faible amplitude peuvent également devenir statistiquement significatifs. Le delta de Cliff est donc utilisé comme mesure de taille d’effet afin de compléter l’information fournie par les tests de comparaison et de caractériser à la fois l’ampleur et la direction des différences observées. MACBETH, RAZUMIEJCZYK et LEDESMA 2011 .

Pour deux échantillons $X = \{x_1, \dots, x_{n_1}\}$ et $Y = \{y_1, \dots, y_{n_2}\}$, chaque paire (x_i, y_j) est comparée et reçoit une contribution définie par :

$$c(x_i, y_j) = \begin{cases} +1 & \text{si } x_i > y_j, \\ 0 & \text{si } x_i = y_j, \\ -1 & \text{si } x_i < y_j. \end{cases} \quad (9)$$

Le delta de Cliff est ensuite obtenu en moyennant ces contributions sur l’ensemble des paires :

$$\delta = \frac{1}{n_1 n_2} \sum_{i=1}^{n_1} \sum_{j=1}^{n_2} c(x_i, y_j). \quad (10)$$

Cette formulation prend explicitement en compte les égalités entre observations : lorsque $x_i = y_j$, la paire est neutre et ne contribue ni positivement ni négativement au résultat. Cette propriété est particulièrement pertinente dans le contexte de cette étude, compte tenu du caractère discret du score G et du nombre d’égalités exactes pouvant être observées

entre les mesures.

Le signe de δ renseigne sur la direction de la différence : une valeur positive indique que les valeurs du groupe X tendent à être supérieures à celles du groupe Y , tandis qu'une valeur négative indique la tendance inverse. La valeur absolue de δ renseigne quant à elle sur l'ampleur de la séparation entre les deux distributions.

Le delta de Cliff est directement relié à la statistique U du test de Mann–Whitney. Dans la convention où U_X désigne la statistique associée au premier groupe, on a :

$$\delta = \frac{2U_X}{n_1 n_2} - 1. \quad (11)$$

Cette relation met en évidence le lien entre le test de Mann–Whitney et la mesure de taille d'effet. Dans la présente étude, le delta de Cliff est calculé directement à partir des comparaisons entre paires, sur l'ensemble des observations disponibles, sans recourir à un sous-échantillonnage.

Le delta de Cliff est mobilisé dans deux contextes complémentaires. Premièrement, lors de la comparaison des modèles sur la période de référence B1–B4, il complète les comparaisons post-hoc de Dunn corrigées par la méthode de Holm : le delta est calculé pour les paires de modèles présentant une différence statistiquement significative, afin d'en quantifier l'ampleur. Deuxièmement, il complète le test de Mann–Whitney utilisé pour comparer la distribution du G-score entre la période de référence B1–B4 et la campagne B5.

Pour interpréter l'amplitude obtenue, les seuils proposés par ROMANO et al. 2006 sont retenus :

$$\text{Amplitude de } |\delta| = \begin{cases} \text{négligeable} & \text{si } |\delta| < 0,147, \\ \text{faible} & \text{si } 0,147 \leq |\delta| < 0,33, \\ \text{moyenne} & \text{si } 0,33 \leq |\delta| < 0,474, \\ \text{élevée} & \text{si } |\delta| \geq 0,474. \end{cases} \quad (12)$$

Pour la comparaison entre la période de référence et B5, un intervalle de confiance à 95 % est également estimé par bootstrap. La procédure repose sur des rééchantillonnages avec remise des observations et sur le recalcul du delta de Cliff pour chaque échantillon rééchantillonné. L'analyse repose sur 500 rééchantillonnages, avec un niveau de confiance de 95 %.

Le delta de Cliff permet ainsi de compléter les conclusions issues des tests de significativité en distinguant une différence statistiquement détectable d'une différence dont l'ampleur est plus ou moins importante. Son interprétation est réalisée conjointement avec la significativité statistique et, pour la comparaison entre B1–B4 et B5, avec l'intervalle de

confiance associé.

2.6.8. Modèle linéaire mixte

La structure expérimentale comporte plusieurs niveaux de répétition. Les observations associées à un même prompt peuvent partager certaines caractéristiques communes et ne doivent donc pas être considérées comme totalement indépendantes.

Un modèle linéaire mixte est utilisé afin de tenir compte de cette structure. Il combine des effets fixes pour les facteurs étudiés et un effet aléatoire associé au prompt.

Un premier modèle, portant uniquement sur la période de référence B1–B4, établit un niveau de base :

$$G \sim \text{Modèle} + \text{Baromètre} + (1 \mid \text{prompt_id}). \quad (13)$$

Cette spécification permet d'estimer les effets du modèle et du baromètre en tenant compte du regroupement des observations par prompt, avant toute analyse spécifique de la variation observée en B5.

Le modèle est ensuite étendu pour comparer la référence au baromètre 5, avec un terme d'interaction :

$$G_{ijkl} = \beta_0 + \beta_{1i} \text{Modèle}_i + \beta_{2j} \text{Période}_j + \beta_{3ij} (\text{Modèle}_i \times \text{Période}_j) + u_k + \varepsilon_{ijkl}, \quad (14)$$

où β_0 est l'ordonnée à l'origine, β_{1i} et β_{2j} les effets fixes respectifs du modèle et de la période, β_{3ij} leur interaction, u_k l'effet aléatoire associé au k -ième prompt, supposé $u_k \sim \mathcal{N}(0, \sigma_u^2)$, et ε_{ijkl} le résidu, supposé $\varepsilon_{ijkl} \sim \mathcal{N}(0, \sigma^2)$ indépendamment des u_k .

L'interaction modèle $\times$ période constitue un élément central de l'analyse : une interaction significative indiquerait que l'évolution du score G entre les périodes n'est pas homogène selon les modèles. Cette analyse complète le test de Mann–Whitney : le premier caractérise la différence globale entre distributions, le modèle mixte permet d'évaluer si l'amplitude de cette différence dépend du modèle.

2.6.9. Corrélation de Spearman

La relation entre le score G et certaines variables quantitatives d'exécution notamment la latence est étudiée à l'aide du coefficient de corrélation de Spearman,

$$\rho_s = \text{corr}(R(G), R(X)), \quad (15)$$

où $R(G)$ et $R(X)$ désignent les rangs du score G et de la variable considérée. Ce choix permet d'étudier une relation monotone sans supposer une relation strictement linéaire ni une distribution normale des variables. Les hypothèses associées sont $H_0 : \rho_s = 0$ contre $H_1 : \rho_s \neq 0$. Cette analyse est conduite à la fois globalement et, lorsque pertinent, séparément par période, afin de déterminer si une association observée sur l'ensemble des données reflète un régime particulier plutôt qu'une relation générale.

2.6.10. Détection des valeurs atypiques

Les valeurs atypiques sont identifiées selon la règle de l'écart interquartile,

$$IQR = Q_3 - Q_1, \quad (16)$$

avec les bornes

$$B_{\text{inf}} = Q_1 - 1,5 \times IQR \quad \text{et} \quad B_{\text{sup}} = Q_3 + 1,5 \times IQR. \quad (17)$$

Une observation est considérée comme atypique lorsqu'elle se situe en dehors de l'intervalle $[B_{\text{inf}}, B_{\text{sup}}]$. Cette procédure n'est pas utilisée comme une règle automatique de suppression : les observations atypiques sont conservées dans le corpus principal et leur influence est étudiée séparément. Cette distinction est particulièrement importante dans le cas de B5 : une observation statistiquement atypique peut correspondre à une anomalie individuelle, mais peut également être associée à un changement réel du régime expérimental.

2.6.11. Analyse de sensibilité et robustesse

Afin d'évaluer la robustesse des conclusions, les statistiques principales sont systématiquement comparées avant et après exclusion des observations identifiées comme atypiques. L'objectif est de distinguer deux situations : une différence principalement portée par quelques observations extrêmes, ou une différence qui persiste malgré leur exclusion et qui reflète alors plus largement la structure du corpus. Une conclusion est considérée comme robuste lorsqu'elle demeure qualitativement stable à l'issue de cette vérification.

2.6.12. Principe général d'interprétation

Les différentes méthodes présentées sont utilisées de manière complémentaire plutôt que comme des analyses indépendantes. Les statistiques descriptives établissent le comportement général du score G ; le coefficient de variation en caractérise la dispersion relative, tandis que l'ICC et l'autocorrélation informent sur la reproductibilité et la dépendance des répétitions. Les tests de Kruskal–Wallis et de Dunn permettent d'étudier les différences entre modèles ; le test de Mann–Whitney caractérise la différence globale entre référence et B5, le delta de Cliff en quantifie l'ampleur. Le modèle linéaire mixte complète ces analyses

en tenant compte de la structure répétée des données et en permettant d'étudier l'interaction entre modèle et période. Enfin, l'analyse des corrélations et des valeurs atypiques permet d'examiner les facteurs associés au score et la robustesse des résultats obtenus.

L'interprétation finale ne repose ainsi jamais sur une seule p -value : elle combine systématiquement la significativité statistique, l'amplitude des effets, leur incertitude, la structure des données, et la stabilité des conclusions à travers les différentes méthodes.

3. Résultats

3.1. Distribution et reproductibilité du G-score

L'analyse débute par l'étude du comportement du G-score dans les baromètres B1 à B4, retenus comme période de référence. Cette étape vise à caractériser à la fois le niveau du score, sa dispersion et sa stabilité lorsque les mêmes configurations expérimentales sont répétées. L'analyse est menée à plusieurs niveaux : distribution globale selon les campagnes, évolution du score au cours des répétitions, variabilité entre prompts et, enfin, mesure quantitative de la reproductibilité.

3.1.1. Niveau et dispersion du G-score

Sur la période de référence B1–B4, le G-score présente un niveau central très stable d'une campagne à l'autre. La moyenne varie de 0,5973 à 0,5989, tandis que la médiane est égale à 0,600 pour chacune des quatre campagnes.

La dispersion varie néanmoins légèrement selon les baromètres. L'écart-type est de 0,0125 pour B1, 0,0212 pour B2, 0,0158 pour B3 et 0,0148 pour B4. B2 présente ainsi la dispersion la plus élevée, tandis que B1 est la campagne la plus concentrée. Malgré ces différences, les premier et troisième quartiles sont tous deux égaux à 0,600 pour les quatre campagnes, conduisant à un intervalle interquartile nul sur l'ensemble de la période de référence.

La Figure 1 met en évidence cette forte concentration du G-score autour de sa valeur centrale. Les distributions des campagnes B1 à B4 présentent un comportement très similaire, tandis que B5 se distingue nettement par un déplacement vers des valeurs plus faibles. Cette différence de comportement entre la période de référence et B5 constitue un élément important pour les analyses consacrées à la rupture de régime.




Figure 1. Distribution du G-score selon le baromètre.

3.1.2. Stabilité du score au cours des répétitions

La stabilité du G-score est ensuite étudiée au niveau des répétitions d’une même configuration modèle–baromètre–prompt. Sur la période de référence, les combinaisons considérées comportent chacune 100 répétitions, numérotées de 1 à 100. Cette structure permet d’examiner directement l’évolution du score au cours des exécutions successives.

La Figure 2 présente l’évolution du G-score au fil des répétitions pour les différents modèles sur les baromètres B1–B4. Les trajectoires restent globalement centrées autour d’un niveau stable et aucune tendance monotone ou dérive temporelle systématique n’est mise en évidence sur l’ensemble des modèles. Cette stabilité globale n’exclut toutefois pas des fluctuations ponctuelles, dont l’amplitude varie selon les configurations considérées.




Figure 2. Évolution du G-score au fil des répétitions sur les baromètres de référence B1–B4. Les bandes indiquent les IC à 95 %.

L’analyse de la variabilité **intra-prompt** apporte un éclairage complémentaire sur cette stabilité. Sur la période de référence, l’écart entre les moyennes des prompts extrêmes est de 0,0052, tandis que l’écart-type moyen au sein des répétitions varie de 0,001666 à 0,012884 selon le prompt. Afin de préciser la répartition de cette variabilité, la somme des carrés totale a été décomposée entre une composante inter-prompt et une composante intra-prompt. La composante intra-prompt représente 98,38 % de la variabilité totale, contre 1,62 % pour la composante inter-prompt. La variabilité du G-score provient donc principalement des différences entre répétitions d’un même prompt plutôt que des différences entre prompts. Ce résultat ne signifie toutefois pas que l’effet du prompt peut être négligé : les répétitions d’un même prompt restent des observations regroupées, dont **la dépendance** doit être prise en compte dans les analyses statistiques suivantes.

Une analyse complémentaire de la dépendance entre répétitions successives montre par ailleurs une autocorrélation médiane proche de zéro ($-0,012$), ce qui indique une dépendance généralement faible entre deux répétitions successives. Certaines configurations présentent toutefois des autocorrélations plus élevées, notamment DeepSeek et Grok-4, pour lesquelles une valeur moyenne de $0,663$ est observée. Cette analyse reste exploratoire et est utilisée comme indicateur complémentaire de la structure temporelle des répétitions.

3.1.3. Évaluation quantitative de la reproductibilité

La reproductibilité est finalement quantifiée à l'aide de deux indicateurs complémentaires : le coefficient de variation (CV), qui caractérise la dispersion relative du score, et l'ICC(1,1), qui évalue la concordance des mesures répétées.

Le coefficient de variation est calculé à partir de l'écart-type et de la moyenne du G-score pour chaque combinaison modèle–prompt. Les résultats montrent que la dispersion relative varie selon les modèles. La Figure 3 présente sa distribution sur les baromètres de référence B1–B4.




Figure 3. Dispersion relative du G-score selon le modèle sur les baromètres de référence B1–B4, mesurée par le coefficient de variation.

Perplexity se distingue notamment par une dispersion relative plus importante que celle observée pour la majorité des autres modèles, cohérente avec sa plus forte variabilité du G-score sur la période de référence.

L'ICC(1,1) est ensuite calculé séparément pour chaque combinaison modèle–baromètre. Parmi les configurations pour lesquelles l'indicateur est estimable, les valeurs restent généralement faibles. La valeur la plus élevée est observée pour Perplexity au baromètre 2 ($ICC = 0,545$), suivie des baromètres 3 et 4 ($ICC = 0,353$ et $0,325$, respectivement). Qwen atteint $ICC = 0,0697$ au baromètre 1, tandis que les autres valeurs estimables sont généralement inférieures à $0,03$.

L'interprétation de ces valeurs doit tenir compte du faible nombre de prompts disponibles : chaque combinaison modèle–baromètre repose sur quatre prompts. Une faible variabilité entre leurs niveaux moyens peut ainsi conduire à un ICC proche de zéro, même lorsque la dispersion absolue des répétitions reste limitée.

Par ailleurs, l'ICC n'est pas estimable lorsque la variance totale du G-score est nulle. Cette situation concerne 18 combinaisons dans les données analysées. GPT-4o présente notamment un G-score constant sur les baromètres de référence. Six autres combinaisons ne permettent pas le calcul de l'indicateur en raison d'un nombre insuffisant de prompts valides après filtrage.

Ainsi, les résultats indiquent une dispersion et une concordance relative variables selon les configurations. L'ICC doit donc être interprété conjointement avec les mesures de dispersion et les analyses de variabilité intra-prompt. Les valeurs détaillées par modèle et par baromètre sont présentées en annexe.

3.2. Hétérogénéité du G-score entre les modèles

L'analyse des baromètres de référence B1–B4 met en évidence des différences de G-score entre les modèles. Les statistiques descriptives présentées dans le Tableau 2 montrent toutefois que les niveaux centraux restent très proches : les médianes sont égales à 0,6000 pour les douze modèles, tandis que les moyennes s'étendent de 0,5867 à 0,6000. Les différences entre modèles sont donc faibles en termes de tendance centrale, tandis que la dispersion varie davantage selon les modèles.

Table 2. Statistiques descriptives du G-score par modèle sur les baromètres de référence B1–B4.

Modèle	n	Moyenne	Médiane	Écart-type
GPT-4o	1600	0,6000	0,6000	0,0000
DeepSeek	1598	0,5999	0,6000	0,0030
Grok-4	1579	0,5999	0,6000	0,0030
Gemini	1599	0,5998	0,6000	0,0051
Claude	1599	0,5997	0,6000	0,0060
Mistral Large	1598	0,5997	0,6000	0,0060
Mistral Small	1600	0,5997	0,6000	0,0063
Qwen	1596	0,5992	0,6000	0,0094
Llama	1599	0,5987	0,6000	0,0124
Cohere	1544	0,5981	0,6000	0,0194
Apertus	1600	0,5967	0,6000	0,0193
Perplexity	1600	0,5867	0,6000	0,0439

3.2.1. Comparaison globale des modèles

Le test de Kruskal–Wallis met en évidence une différence statistiquement significative entre les distributions de G-score des douze modèles :

$$H = 877,38, \quad p = 4,52 \times 10^{-181}. \quad (18)$$

L’hypothèse nulle d’égalité des distributions est donc rejetée. Compte tenu du nombre important d’observations, cette significativité doit toutefois être distinguée de l’importance pratique des écarts observés. Les comparaisons post-hoc permettent de préciser cette hétérogénéité.

3.2.2. Comparaisons post-hoc entre modèles

Les comparaisons deux à deux réalisées à l’aide du test de Dunn, avec correction de Holm, identifient 22 paires de modèles présentant une différence statistiquement significative. Ces différences restent cependant de faible amplitude : l’ensemble des valeurs absolues du delta de Cliff est inférieur à 0,147, seuil retenu pour qualifier l’amplitude de l’effet comme négligeable.

Les effets les plus importants concernent principalement les comparaisons impliquant Perplexity. Le delta de Cliff atteint $\delta = 0,0906$ pour la comparaison avec GPT-4o, 0,0900

avec DeepSeek et $-0,0900$ avec Grok-4. Les autres comparaisons impliquant Perplexity présentent également des tailles d'effet inférieures à $0,09$ en valeur absolue.

Ainsi, les différences entre modèles sont statistiquement détectables, mais leur amplitude reste négligeable selon les seuils retenus. Le résultat met donc en évidence une hétérogénéité inter-modèles sur le plan statistique, sans pour autant révéler de différence importante entre les niveaux de G-score dans les conditions de référence.

Les résultats détaillés des 22 comparaisons significatives sont présentés dans l'Annexe 5.3.

3.3. Rupture du G-score au baromètre B5

La période B1–B4 ayant établi un niveau de référence stable, l'analyse porte ensuite sur la campagne B5. Celle-ci se distingue nettement par une diminution du G-score, visible à la fois dans l'évolution du score moyen au cours des campagnes et dans la distribution des observations.

3.3.1. Mise en évidence de la rupture

Sur la période de référence B1–B4, la moyenne du G-score est de $0,5982$, contre $0,5266$ en B5, soit une diminution de $0,0716$. La Figure 4 montre que cette baisse constitue une rupture nette par rapport au niveau relativement stable observé lors des campagnes de référence.




Figure 4. Évolution du G-score moyen entre les baromètres B1 et B5.

3.3.2. Amplitude de la différence entre la référence et B5

La comparaison directe des distributions confirme le déplacement du G-score vers des valeurs plus faibles en B5 (Figure 5).




Figure 5. Distribution du G-score : période de référence B1–B4 et baromètre B5, représentée sous forme de densité normalisée.

Le test de Mann–Whitney met en évidence une différence statistiquement significative entre les deux distributions. Cette différence est également importante en termes d’amplitude, avec un delta de Cliff de

$$\delta = 0,9463, \quad IC_{95\%} = [0,9384 ; 0,9543]. \quad (19)$$

Selon les seuils retenus, cette valeur correspond à un effet élevé. La baisse observée en B5 traduit ainsi une rupture substantielle de la distribution du G-score, et non une simple fluctuation autour du niveau de référence.

3.3.3. Hétérogénéité de la rupture selon les modèles

Une question complémentaire est de déterminer si l’effet de la période dépend du modèle : *la rupture observée entre la période de référence et B5 présente-t-elle la même amplitude pour tous les modèles ?*

Pour répondre à cette question, deux modèles linéaires mixtes sont comparés sur les observations de la période de référence B1–B4 et de B5. La structure répétée des données est prise en compte par l’introduction d’un effet aléatoire associé au prompt.

Le premier modèle, sans interaction, s’écrit :

$$M_0 : \quad G \sim \text{Modèle} + \text{Période} + (1|\text{prompt}) \quad (20)$$

Le second modèle ajoute l’interaction entre le modèle et la période :

$$M_1 : \quad G \sim \text{Modèle} + \text{Période} + \text{Modèle} \times \text{Période} + (1|\text{prompt}) \quad (21)$$

La comparaison des deux modèles par test du rapport de vraisemblance montre que l’ajout de l’interaction améliore significativement l’ajustement :

$$\chi^2 = 361,729, \quad ddl = 11, \quad p = 7,973 \times 10^{-71}. \quad (22)$$

L'interaction modèle $\times$ période est donc hautement significative. La rupture observée en B5 est ainsi générale, mais son amplitude varie significativement selon les modèles.

Cette analyse apporte une information complémentaire à la comparaison globale entre B1–B4 et B5 : elle montre que la rupture ne peut pas être décrite par un effet de période identique pour tous les modèles. Elle met ainsi en évidence une hétérogénéité du comportement inter-modèles, sans pour autant permettre, à elle seule, de conclure qu'un modèle est plus ou moins reproductible qu'un autre.

3.3.4. Variables d'exécution associées au G-score

Afin d'examiner si les variables d'exécution peuvent être associées au G-score, une analyse de corrélation de Spearman est d'abord réalisée sur l'ensemble des campagnes. Les corrélations sont ensuite calculées séparément sur la période de référence B1–B4 et sur B5, afin de distinguer une association générale d'un éventuel effet lié à une campagne particulière.

Période	Latence		Nombre de tokens	
	ρ_s	p	ρ_s	p
Toutes campagnes	0,5662	< 0,001	-0,0302	< 0,001
B1–B4 (référence)	-0,0011	0,875	-0,0362	< 0,001
B5	-0,0169	0,242	-0,0226	0,117

Table 3. Corrélations de Spearman entre le G-score et les variables d'exécution, selon la période.

Sur l'ensemble des campagnes, une corrélation positive est observée entre la latence et le G-score ($\rho_s = 0,5662$, $p < 0,001$). Cependant, cette association disparaît lorsque les périodes sont analysées séparément : elle est quasi nulle sur B1–B4 ($\rho_s = -0,0011$, $p = 0,875$) et sur B5 ($\rho_s = -0,0169$, $p = 0,242$). La corrélation globale semble ainsi principalement liée aux différences entre campagnes plutôt qu'à une relation intrinsèque entre la latence et le G-score.

Pour le nombre de tokens, les coefficients restent proches de zéro dans toutes les périodes. La corrélation est de $\rho_s = -0,0302$ sur l'ensemble des campagnes, de $\rho_s = -0,0362$ sur B1–B4 et de $\rho_s = -0,0226$ sur B5. En B5, cette association n'est pas significative ($p = 0,117$).

Ainsi, aucune des deux variables d'exécution étudiées ne présente d'association substantielle avec le G-score au sein de B5. Ces résultats ne suggèrent donc pas que la latence ou le

nombre de tokens expliquent, à eux seuls, la rupture observée lors de cette campagne.

3.4. Évolution du G-score après B5

Après avoir établi que la variation observée en B5 concerne l'ensemble des modèles, avec une amplitude qui varie néanmoins selon le modèle, il reste à déterminer si cette variation persiste dans les campagnes suivantes ou si elle constitue un épisode ponctuel suivi d'un retour vers le niveau de référence.

3.4.1. Comparaison globale : référence, B7 et B8

Les campagnes B7 et B8 montrent une remontée nette du G-score après la baisse observée en B5. La moyenne du G-score est de 0,598 en B7 et de 0,600 en B8, contre 0,598 sur la période de référence B1–B4. Ces valeurs sont très proches du niveau de référence et contrastent avec la moyenne observée en B5 (0,527).

Ce rapprochement constitue un premier indice descriptif d'un retour du G-score vers son niveau antérieur. La comparaison des campagnes de suivi doit toutefois être complétée par une analyse tenant compte de la structure répétée des données et des différences entre modèles.

3.4.2. Hétérogénéité de l'évolution selon les modèles

Une question complémentaire consiste à déterminer si le retour vers le niveau de référence est homogène entre les modèles : *l'évolution du G-score entre la période de référence, B7 et B8 dépend-elle du modèle ?*

Pour répondre à cette question, deux modèles linéaires mixtes sont comparés sur les observations de la période de référence B1–B4 et des campagnes B7 et B8. La structure répétée des données est prise en compte par l'introduction d'un effet aléatoire associé au prompt.

Le premier modèle, sans interaction, suppose que l'évolution entre les trois périodes est commune à l'ensemble des modèles :

$$M_0 : G \sim \text{Modèle} + \text{Période} + (1|\text{prompt}) \quad (23)$$

Le second modèle autorise une évolution différente selon le modèle en introduisant une interaction entre le modèle et la période :

$$M_1 : G \sim \text{Modèle} + \text{Période} + \text{Modèle} \times \text{Période} + (1|\text{prompt}) \quad (24)$$

La comparaison des deux modèles par test du rapport de vraisemblance montre que l'ajout de l'interaction améliore très significativement l'ajustement :

$$\chi^2 = 821,187, \quad ddl = 22, \quad p = 1,848 \times 10^{-159}. \quad (25)$$

L'interaction modèle $\times$ période est donc hautement significative. L'évolution du G-score entre la période de référence, B7 et B8 n'est pas identique pour les douze modèles. Le retour vers le niveau de référence est globalement observé, mais son amplitude varie significativement selon le modèle.

3.4.3. Amplitude du retour par modèle

La Figure 6 présente, pour chaque modèle, les écarts entre le G-score estimé en B7 et B8 et le niveau **estimé** sur la période de référence. Ces valeurs sont obtenues à partir **prédictions du modèle mixte** et permettent de comparer l'ampleur du retour pour chaque modèle




Figure 6. Écart estimé du G-score en B7 et B8 par rapport à la période de référence, selon le modèle.

Les écarts présentés dans cette figure permettent de comparer le niveau observé en B7 et B8 à celui de la période de référence. La heatmap présentée en Annexe 5.1 complète cette analyse, et permet, de son côté, de comparer les valeurs observées du G-score pour chaque modèle et chaque baromètre. Elle permet notamment de visualiser directement la rupture commune en B5 et le retour vers des niveaux proches de 0,600 en B7 et B8.

Pour la majorité des modèles, les écarts estimés par rapport à leur propre niveau de référence restent très faibles. Dix des douze modèles présentent un écart inférieur à 0,004 en valeur absolue en B7 comme en B8.

Cohere constitue le cas le plus marqué en B7, avec un écart estimé de $-0,0161$. Cet écart

devient toutefois quasi nul en B8 (+0,0019), indiquant un rapprochement beaucoup plus important avec son niveau de référence.

Perplexity présente quant à elle l'écart positif le plus élevé, de +0,0133 en B7 comme en B8. Cet écart doit être interprété relativement à son propre niveau de référence sur B1–B4, qui est plus faible que celui de la majorité des modèles. Son retour vers un niveau proche de 0,600 se traduit ainsi par une amplitude de retour plus importante lorsqu'elle est mesurée relativement à ce niveau de référence.

Ces résultats indiquent que, malgré une tendance générale au retour vers les niveaux de référence après B5, l'amplitude de ce retour varie selon les modèles. L'écart reste faible pour la majorité d'entre eux, tandis que Cohere et Perplexity présentent les écarts les plus marqués, dans des directions différentes.

3.4.4. Trajectoire complète après la rupture




Figure 7. Trajectoire du G-score moyen entre la période de référence, B5, B7 et B8.

La trajectoire met en évidence une baisse nette du G-score en B5, suivie d'une remontée en B7 puis d'un retour vers des niveaux proches de la référence en B8 pour la majorité des modèles. La perturbation observée en B5 apparaît ainsi principalement **transitoire**. Les différences entre modèles concernent surtout l'amplitude et la vitesse du retour, avec notamment un retour plus tardif pour Cohere en B7 et un rattrapage plus marqué pour Perplexity, cohérent avec son niveau de référence initialement plus bas. Voir également la Figure 5.4 en annexe pour le détail des trajectoires individuelles.

3.5. Robustesse des résultats aux valeurs atypiques

Une analyse complémentaire est menée afin de vérifier dans quelle mesure les observations atypiques influencent les résultats obtenus. Les observations sont identifiées à l'aide de la règle de l'écart interquartile, puis conservées dans l'analyse principale. Leur influence est évaluée séparément, afin de distinguer la présence de quelques valeurs extrêmes d'un changement plus général du comportement du score.

3.5.1. Identification des valeurs atypiques

La règle de l'IQR identifie 4 965 observations atypiques sur les 33 401 observations analysées, soit 14,86 % du corpus. Leur répartition est toutefois très inégale : 4 653 de ces observations sont situées en B5.

Cette concentration en B5 est cohérente avec le déplacement du G-score déjà observé lors de cette campagne. Dans ce contexte, le caractère atypique d'une observation ne signifie donc pas nécessairement qu'elle constitue une anomalie individuelle ; il peut également traduire le changement de régime mis en évidence en B5.

3.5.2. Analyse de sensibilité

Afin d'évaluer l'influence de ces observations sur les conclusions relatives à la rupture de B5, les moyennes sont comparées avant et après leur exclusion temporaire.

Période	Avec atypiques	Sans atypiques	Variation
Référence B1–B4	0,5982	0,6000	+0,0018
B5	0,5266	0,6000	+0,0734

Table 4. Sensibilité du G-score à l'exclusion des observations identifiées comme atypiques.

L'exclusion des 4 965 observations atypiques modifie très peu la moyenne de référence, qui passe de 0,5982 à 0,6000. En revanche, la moyenne de B5 passe de 0,5266 à 0,6000, soit une variation de +0,0734.

Cette différence s'explique principalement par la forte concentration des observations identifiées comme atypiques en B5. Leur exclusion retire ainsi une grande partie des observations correspondant au régime particulier de cette campagne. Les observations atypiques sont donc conservées dans l'analyse principale : leur présence constitue ici davantage un indicateur du changement de régime en B5 qu'un ensemble de valeurs aberrantes isolées.

3.5.3. Erreurs d'exécution selon les baromètres

La qualité des observations a également été examinée à travers le taux d'erreur d'exécution. Le nombre d'erreurs reste faible sur l'ensemble des campagnes, mais varie selon les baromètres.

Baromètre	Observations	Erreurs	Taux d'erreur (%)
B1	4800	25	0,521
B2	4800	20	0,417
B3	4800	1	0,021
B4	4800	42	0,875
B5	4800	2	0,042
B7	4800	1	0,021
B8	4800	108	2,250

Table 5. Nombre et taux d'erreurs d'exécution selon le baromètre.

Les taux d'erreur restent inférieurs à 1 % pour B1–B7, y compris en B5 où ils atteignent seulement 0,042 %. B8 présente en revanche un taux plus élevé de 2,250 %. La rupture observée en B5 ne semble donc pas liée à une augmentation des erreurs d'exécution.

plusieurs limites. Le protocole repose sur seulement 4 prompts, ce qui limite la généralisation des résultats, notamment pour les analyses de reproductibilité. Les observations répétées d'un même prompt ne sont également pas indépendantes ; cette structure a été prise en compte dans les modèles mixtes.

L'analyse des valeurs atypiques doit aussi être interprétée avec prudence. La forte concentration du G-score autour de 0,6000 conduit à une identification importante des observations de B5 par la règle de l'IQR. Dans ce contexte, ces observations semblent davantage refléter le changement de régime observé en B5 que des valeurs aberrantes isolées.

Enfin, les résultats caractérisent le comportement du G-score dans les conditions étudiées. Ils ne permettent pas, à eux seuls, de conclure à une propriété d'invariance générale du score dans d'autres modèles, prompts ou conditions expérimentales. Le G-score est ici considéré comme un indicateur de stabilité ou de comportement et non comme une mesure directe de la factualité ou de la qualité des réponses.

4. Discussion

4.1. Synthèse des résultats

L'analyse menée sur les 33 600 observations permet de dégager un comportement relativement stable du G-score dans les conditions de référence, tout en mettant en évidence une rupture nette lors d'une campagne particulière. Cette conclusion ne repose pas sur une seule mesure ou un seul test statistique, mais sur la convergence de plusieurs analyses complémentaires portant sur la distribution du score, sa reproductibilité, les différences entre modèles, les changements entre campagnes et la robustesse des résultats.

Sur la période de référence B1–B4, le G-score présente un niveau central très stable : les moyennes des quatre campagnes varient seulement de 0,5973 à 0,5989, tandis que la médiane reste égale à 0,600 pour chacune d'elles. Les répétitions d'une même configuration ne montrent par ailleurs aucune dérive temporelle systématique. Cette stabilité du niveau moyen s'accompagne néanmoins de différences de dispersion selon les prompts et les modèles, ce qui montre que la reproductibilité ne se résume pas à la proximité des moyennes.

Le principal changement apparaît en B5. La moyenne du G-score passe de 0,5982 sur la période de référence à 0,5266 en B5, soit une diminution de 0,0716. Cette rupture est observée sur l'ensemble des modèles, mais son amplitude varie selon ceux-ci. Le modèle mixte confirme cette hétérogénéité par une interaction significative entre le modèle et la période ($\chi^2 = 361,729$, $ddl = 11$, $p = 7,973 \times 10^{-71}$).

La rupture n'est toutefois pas durable. Le G-score revient à 0,598 en B7 puis à 0,600 en B8, des niveaux très proches de ceux de la période de référence. Le retour n'est pas parfaitement homogène entre les modèles, comme l'indique également le modèle mixte ($\chi^2 = 821,187$, $ddl = 22$, $p = 1,848 \times 10^{-159}$).

Les analyses complémentaires ne font pas apparaître de facteur d'exécution simple permettant d'expliquer cette rupture. Les associations avec la latence et le nombre de tokens sont faibles lorsque B5 est analysée séparément, tandis que le taux d'erreur reste très faible (0,042 %). Ces éléments permettent ainsi d'écarter certaines explications immédiates, sans pour autant identifier la cause de la rupture.

Enfin, l'analyse de sensibilité aux valeurs atypiques renforce la lecture d'un changement de régime plutôt que celle d'une simple influence de quelques observations extrêmes. Les observations atypiques sont majoritairement concentrées en B5 et leur traitement ne remet pas en cause le niveau de référence. Leur exclusion rapproche en revanche fortement la moyenne de B5 de 0,6000, ce qui confirme que la distribution particulière de cette campagne constitue un élément central du phénomène observé.

4.2. Évaluation de l'hypothèse d'invariance

Pris dans leur ensemble, **les résultats ne permettent pas de retenir l'hypothèse d'une invariance stricte du G-score**. Une telle invariance supposerait que le comportement du score reste suffisamment stable malgré les changements de campagnes, de modèles et de conditions de mesure. Or, la rupture nette observée en B5 montre qu'une variation importante peut apparaître dans certaines conditions.

Cette conclusion **ne signifie cependant pas que le G-score soit instable de manière générale**. La stabilité du niveau moyen observée en B1–B4, ainsi que le retour vers des niveaux proches de la référence en B7 et B8, montrent qu'un comportement globalement stable peut être retrouvé lorsque les conditions redeviennent comparables.

L'hétérogénéité observée entre les modèles constitue également un élément important. L'ampleur de la rupture en B5 comme celle du retour vers la référence varie selon les systèmes. Le G-score ne réagit donc pas de manière strictement identique aux changements de campagne, même si la tendance générale est commune.

La conclusion sur la stabilité conditionnelle repose ainsi sur la convergence de plusieurs analyses complémentaires : stabilité en B1–B4, rupture en B5, hétérogénéité entre modèles, retour vers la référence en B7–B8 et absence d'association substantielle avec les principales variables d'exécution étudiées. Elle ne repose pas sur un unique test statistique.

En revanche, les données disponibles ne permettent pas d'établir la cause de la rupture observée en B5. Elles permettent d'en caractériser l'ampleur, son caractère commun aux modèles et son évolution ultérieure, mais pas d'identifier avec certitude le mécanisme à l'origine de cet épisode.

4.3. Limites de l'étude

La principale limite concerne le nombre de prompts disponibles. Le protocole repose sur quatre prompts, ce qui permet une analyse répétée et structurée, mais limite la généralisation des résultats à des contenus plus diversifiés. Les différences observées selon les prompts peuvent notamment refléter des caractéristiques propres aux exemples utilisés.

Les répétitions d'un même prompt introduisent également une structure de dépendance entre les observations. Cette dépendance est prise en compte dans les modèles mixtes, mais elle constitue une limite lorsqu'il s'agit d'extrapoler les résultats à d'autres configurations expérimentales.

L'analyse des valeurs atypiques doit également être interprétée avec prudence. La forte concentration du G-score autour de 0,6000 conduit à identifier un nombre particulièrement important d'observations de B5 comme atypiques selon la règle de l'IQR. Cette méthode permet de mettre en évidence le changement de régime, mais ne permet pas à elle seule de

distinguer une anomalie individuelle d'une modification réelle des conditions de mesure.

Enfin, les conclusions restent liées au périmètre expérimental considéré. Les résultats établissent des propriétés du G-score dans les conditions étudiées, mais ne permettent pas de conclure qu'elles se maintiendront nécessairement avec d'autres prompts, modèles, campagnes ou environnements d'exécution. La principale limite porte donc sur la **généralisation** des résultats, et non sur l'existence des phénomènes statistiques observés dans le corpus analysé.

4.4. Perspectives pour une étude plus large

Une première extension consisterait à augmenter le nombre de prompts afin de déterminer si la stabilité observée se maintient sur des contenus plus variés et de mieux séparer les effets propres aux prompts de ceux qui relèvent du comportement général du score.

La rupture observée en B5 constitue également un phénomène important à répliquer. Une étude ultérieure pourrait reproduire des campagnes dans des conditions aussi proches que possible de celles ayant conduit à la rupture, afin de déterminer si ce changement de régime est reproductible ou s'il est spécifique à la campagne étudiée.

Il serait également pertinent d'augmenter le nombre de répétitions et d'élargir le nombre de modèles et de campagnes. Cette extension permettrait de mieux caractériser la variabilité du score, d'évaluer la persistance des différences entre modèles et de tester plus largement la stabilité conditionnelle observée ici.

Enfin, une analyse complémentaire intégrant davantage de variables décrivant les conditions d'exécution permettrait de rechercher plus précisément les facteurs associés aux changements de régime. La combinaison de ces informations avec d'autres indicateurs des sorties évaluées pourrait également aider à mieux comprendre ce que reflètent les variations du G-score.

L'objectif d'une telle extension ne serait donc pas simplement de rechercher une confirmation de l'invariance, mais de déterminer dans quelles conditions la stabilité du G-score se maintient, dans quelles conditions elle est rompue, et si le schéma observé dans cette étude peut être reproduit sur un périmètre expérimental plus large.

5. Annexes

5.1. Annexe – Niveau moyen du G-score selon le modèle et le baromètre




Figure 8. Heatmap-Moyenne du G score selon le modèle et le baromètre

5.2. Annexe — Reproductibilité : ICC(1,1) par modèle et par baromètre

Modèle	B1	B2	B3	B4
Claude Sonnet 4.5	–	–	0,010	–
Cohere Command-A	–	0,004	–	–
DeepSeek	–	–	0,000	–
Gemini 2.5 Flash	0,000	–	–	–
Mistral Small	0,000	0,016	–	0,000
Apertus 70B	-0,001	-0,004	0,024	0,016
Mistral Large	0,000	0,010	0,000	–
GPT-4o	–	–	–	–
Perplexity Sonar	0,010	0,545	0,353	0,325
Qwen Plus	0,070	0,000	0,000	–
Llama 3.3 70B	0,002	-0,002	0,012	–
Grok-4	–	–	–	–

Table 6. ICC(1,1) par modèle et par baromètre sur la période de référence B1–B4. Les valeurs indiquées par – correspondent aux combinaisons pour lesquelles l’ICC n’est pas estimable.

Note. L’ICC(1,1) est calculé à partir des répétitions des quatre prompts disponibles pour chaque combinaison modèle–baromètre. Six combinaisons n’ont pas pu être analysées faute d’un nombre suffisant de prompts et dix-huit présentent une variance totale nulle, rendant l’ICC non estimable. Les valeurs proches de zéro indiquent une faible corrélation intra-classe dans la configuration considérée ; des valeurs négatives peuvent apparaître lorsque la composante de variance inter-groupes estimée est nulle ou très faible.

5.3. Annexe – Comparaisons post-hoc entre modèles

Table 7. Paires de modèles statistiquement significatives (test de Dunn, correction de Holm), avec delta de Cliff associé. Période de référence B1–B4. Les 22 paires sont toutes d’amplitude négligeable.

Modèle 1	Modèle 2	p (Holm)	δ	Amplitude
GPT-4o	Perplexity Sonar	$3,59 \times 10^{-107}$	0,0906	négligeable

Modèle 1	Modèle 2	p (Holm)	δ	Amplitude
DeepSeek	Perplexity Sonar	$1,20 \times 10^{-105}$	0,0900	négligeable
Perplexity Sonar	Grok-4	$5,26 \times 10^{-105}$	-0,0900	négligeable
Gemini 2.5 Flash	Perplexity Sonar	$3,11 \times 10^{-104}$	0,0894	négligeable
Claude Sonnet 4.5	Perplexity Sonar	$2,25 \times 10^{-101}$	0,0882	négligeable
Mistral Large	Perplexity Sonar	$2,40 \times 10^{-101}$	0,0882	négligeable
Mistral Small	Perplexity Sonar	$5,27 \times 10^{-100}$	0,0877	négligeable
Perplexity Sonar	Qwen Plus	$1,49 \times 10^{-91}$	-0,0841	négligeable
Cohere Command-A	Perplexity Sonar	$8,16 \times 10^{-84}$	0,0803	négligeable
Perplexity Sonar	Llama 3.3 70B	$2,16 \times 10^{-77}$	-0,0776	négligeable
Apertus 70B	Perplexity Sonar	$1,82 \times 10^{-46}$	0,0611	négligeable
Apertus 70B	GPT-4o	$1,77 \times 10^{-12}$	-0,0312	négligeable
DeepSeek	Apertus 70B	$5,65 \times 10^{-12}$	0,0306	négligeable
Apertus 70B	Grok-4	$6,65 \times 10^{-12}$	-0,0306	négligeable
Gemini 2.5 Flash	Apertus 70B	$1,70 \times 10^{-11}$	0,0300	négligeable
Claude Sonnet 4.5	Apertus 70B	$1,51 \times 10^{-10}$	0,0287	négligeable
Apertus 70B	Mistral Large	$1,51 \times 10^{-10}$	-0,0287	négligeable
Mistral Small	Apertus 70B	$4,17 \times 10^{-10}$	0,0281	négligeable
Apertus 70B	Qwen Plus	$1,63 \times 10^{-07}$	-0,0243	négligeable
Cohere Command-A	Apertus 70B	$1,25 \times 10^{-05}$	0,0212	négligeable
Apertus 70B	Llama 3.3 70B	$9,88 \times 10^{-04}$	-0,0176	négligeable
GPT-4o	Llama 3.3 70B	$3,78 \times 10^{-02}$	0,0138	négligeable

5.4. Annexe – Trajectoires du G-score par modèle et par baromètre




Figure 9. Trajectoire du G-score entre la période de référence, B5, B7 et B8, avec représentation des trajectoires individuelles des modèles.

5.5. Annexe – Valeurs atypiques par baromètre

Baromètre	Nombre d'observations atypiques
B1	41
B2	86
B3	70
B4	63
B5	4653
B7	44
B8	8

Table 8. Répartition des observations identifiées comme atypiques selon le baromètre.

Références

- MACBETH, G., E. RAZUMIEJCZYK et R. D. LEDESMA (2011). “Cliff’s Delta Calculator : A Non-Parametric Effect Size Program for Two Groups of Observations”. In : *Universitas Psychologica* 10.2, p. 545-555.
- ROMANO, J. et al. (2006). “Appropriate Statistics for Ordinal Level Data : Should We Really Be Using t-test and Cohen’s d for Evaluating Group Differences on the NSSE and Other Surveys”. In : *Annual Meeting of the Florida Association of Institutional Research*, p. 1-33.